

六角色自主软件生产模拟演练材料

[公开静态体验（可信固定 Mock 与材料；无后端、无实时模型调用）](#)

[本机管线入口](#)：<http://127.0.0.1:4420/#production> · 构建与启动见 RUNBOOK.md。静态入口不能配置 Key 或执行 live。

[当前审查结论与未达标项（REVIEW.md）](#)；主阅读文档描述当前 publisher 版本，历史运行配置只以原始 JSON 为准。

申报状态：工程演练材料，不是 L4 已达标声明。

三个需求均由用户授权自拟，角色响应及源码为 Mock 夹具。实际 Chromium Gate 已执行；这三项生成模型请求为零，真实 Jev 决策在附页分列。本批不能满足“至少三项真实需求”，也不能证明内部 Agent 已自主编写交付。

历史录屏（平台 891fedc）：继承原 demo.webm；当时 iframe 预览边界已发现自导航外联风险，现已关闭，不能作为现版本安全证据。原视频没有重录或改写。

Mock Gate 通过

3 / 3

真实生成任务

0

真实生成记录通过率

unknown

真实业务需求

0

1 基本信息

管线：Agent Delivery Studio，有界单 HTML 软件生产。团队：用户负责目标与授权，外层开发 Agent 建设平台，内部六角色负责执行；成员姓名与正式团队名单未填写。需求类型：新建应用、受控模板功能扩展、模拟缺陷修复。

原 Mock 运行平台 commit：891fedcab0f3c5994c7e92f7874e610b3b6354b8

材料导出与审查工具 commit：b899b0e4d7ae9b3cd91efa9a55969ab57c954215

冻结申报基线：b66122c21604fdb2ecdcbafeb89c3d5ad8cde1466

原记录生成时点：2026-10-06T21:40:07.603Z；本报告渲染时点：2026-10-07T00:22:03.083Z。保留原运行版本，展示修订不重跑模型、不改变实验。文件 hash 可核对，不是防篡改签名或供应商账单。

2 管线设计与人工边界



全部可替换角色输出都经过 Verifier；失败 → 项目经理反馈 → 研发，最多两次返修。控制面保管 Key，执行面只运行受限 HTML。

环节	AI 职责	门禁标准
产品经理	一句话扩展为可操作目标、范围和验收	目标对应、结构有效、不虚构
研究员	分析约束与未知项	无搜索工具就不声称联网研究
项目经理	拆任务，思考与设计，测试反馈后重规划	有界轮次/费用/时间；无权绕过 Gate
测试	独立定义可执行检查	合法 CSS、交互结果、研发前冻结 hash
研发	实现完整 HTML，按证据有限返修	不修改冻结测试、不执行宿主脚本
Verifier	每次可替换输出的候选审查与选择	无合格答案则弃权；评分不是概率
Chromium Gate	实际页面加载与交互验收	精确结果与实际条目数；失败不能被评分覆盖
交付	源码、日志、契约、manifest 与指标	必要证据完整才完成；unknown 不当零

人工初始职责：提供目标、范围、模型、权限、预算、验收，并决定是否采用产物。运行中的取消可被系统记录；外部人工改代码或验收需另行审计，空数组不是完全无人介入证明。当前项目经理是固定阶段的有限反馈闭环，不是任意任务 DAG 调度器。

可复用性：live 不使用需求关键词特判或演示产物回退；共享版本化契约、加密配置和浏览器执行器。受控仓库、Node 构建与依赖安装仍需安全容器验证，不在本批范围。

3 三项模拟需求与输入

编号	类型	背景	输入材料	冻结业务验收	难度	结果
MOCK-01	新建 Create	用最小协作工具验证从一句话目标到可交互 HTML 的新建应用路径。	一句话需求与冻结验收；受限 HTML 执行范围	初始无任务；添加“准备发布”后仅出现一条同名任务；输入框清空；能标记完成并显示完成统计；删除后列表与统计归零。	低 Low	完成 Completed
MOCK-02	增量 Feature	演练增量需求、原有交互回归与功能验收；本批不是任意既有仓库的真实修改。	受控待办模板 fixture v1；新增筛选需求；原交互回归契约	添加“编写方案”和“执行测试”；完成其中一条；未完成筛选只显示另一条，已完成筛选只显示完成项；切回全部恢复两条；统计保留总数与完成数。	中 Med	完成 Completed
MOCK-03	修复 Bugfix	检查反例、错误反馈与修复后的回归；fixture 的修复不能计为真实模型自主修复。	空输入缺陷描述与重现步骤；受控待办模板 fixture v1；负向用例	空输入、纯空格提交均保持零项并显示提示；连续添加“回归接口”和“检查日志”恰好两项；删除第一条后第二条仍在，总数为一。	中 Med	完成 Completed

来源：用户于 2026-10-07 授权自拟，没有真实工单或需求方。三项共用受控待办应用，便于验证交互回归；不能据此声称跨产品泛化。完整原话、来源与限制在 requirements.json，各需求 input.json 为执行快照。

4 执行记录与复现

每案例目录保存 input.json、run.json、intermediate.json、frozen-contract.json、gate.json、events.ndjson、源码、manifest 和 evidence.json；失败也保留。历史录屏（平台 891fedc）：继承原 demo.webm；当时 iframe 预览边界已发现自导航外联风险，现已关闭，不能作为现版本安全证据。原视频没有重录或改写。

离线重渲：npm run production:package -- --from-package output/pdf/原材料目录，先校验旧包 hash，新目录逐字继承原证据，不访问服务、不产生模型请求。新的免费 Mock 运行另用 npm run production:package -- --record，产生独立运行 ID，不能与历史记录合并成同一冻结实验。

5 指标统计与预测口径

需求	终态	行为 Gate	墙钟时间	模拟环节记录	生成请求	生成 Token	生成费用	返修	系统取消
MOCK-01	完成 Completed	通过	1084 ms	12	0	0 / 0	0 USD	0	0
MOCK-02	完成 Completed	通过	1186 ms	12	0	0 / 0	0 USD	0	0
MOCK-03	完成 Completed	通过	1197 ms	12	0	0 / 0	0 USD	0	0

Mock 3/3 通过属于夹具功能验证。真实自主环节占比与实测增效为 unknown，不认证自主交付。模拟环节记录不是 HTTP 请求；表中 0 Token/0 模型费用只属于这三项 Mock 生成，不是全包没有供应商请求。独立 Jev 总账在附页与 materials-summary.json 明确列出；外层开发、机器和录屏成本未统计。

需求	人工人日预测	依据与限制
MOCK-01	0.5—1	预测：熟悉 HTML 的研发完成实现、自测与交付；1 人日按 8 小时，不是实测对照。
MOCK-02	0.3—0.75	预测：熟悉既有小页面的研发扩展并回归；不用于已实测增效。
MOCK-03	0.25—0.5	预测：定位和修复单页输入校验并回归；待同范围人工对照验证。

增效：没有同目标、同范围、同验收的人工实测对照，不计算已实现增效倍数。实际运行费用采用声明单价估算，不是供应商发票；缺原始 usage 为 unknown。真实生成首批内部上限每次 5 USD、合计 15 USD；决策对照独立批次限额 1 USD。

6 归因与改进

本批 Mock 失败数 0。旧六次真实交付失败属于旧工程配置，原始负结果不改写，也不与本批 Mock 合并。本次审查发现旧 iframe 可自行导航外联，已从应用撤下；模型生成 HTML 仅下载为附件，预览改受控 Chromium 截图。浏览器截图仍非任意代码安全容器，恶意代码隔离与资源限额继续受实际测试约束。

7 L4 自评与复用推广计划

项目	本批结论
有界自主控制	固定阶段六角色、冻结验收、候选验证、最多两次返修及取消；不是任意DAG或无限成长
实际模型自主交付	真实生成任务未实测；不可称最小真实闭环已通过，Jev决策不能替代研发
正式 L4 参考线	用户没有提供；仅操作性自评，不是官方认证
三项真实需求	未满足，本包主案例明确为模拟需求
通用 L5	不宣称；任意环境、仓库和无限权限不支持

参考项目与下一步

[LLM-as-a-Verifier](#)：借鉴细粒度评价标准、候选选择与反馈；本批结构化序数评分没有复现 score-token logprob 期望/PPT，也不是校准通过概率。固定人工构造池的首候选与选中结果见 Jev 附页，不证明泛化或最佳答案。

[AnyJev](#)：SDK 尚未接入；下一步研究低风险 proceed/revise/abstain/stop 类型决策，以及支持 logprobs 的模型和独立标注集。其 L0/L1/L2 是决策读出等级，与本项目研发 L4/L5 无关。

1. 在新页面配置六角色模型与 Key，运行三个模拟需求的真实模型实验，保留全部失败。
2. 验证容器安全，扩展受控仓库的小应用、增量和 Bug 路径，交付 patch/lockfile/构建证据。
3. 固定配置、预登记三类任务各三次；未见任务不得用于调优，按全部尝试统计。
4. 补充真实业务需求与正式参考线、同范围人工/无Verifier成本对照后，才形成达标、增效或推广结论。

虚拟社会研发线保持独立；不修改原 worktree、main、冻结 Tag 或旧申报附件。公开静态入口不运行本机 Harness 后端。

核心能力：LLM-as-a-Verifier + 真实 Jev 决策

生成模型产物先过结构预检，再经覆盖性、一致性、受限范围三个 Score，范围 Noul 和含弃权的 Choice。问题在一请求批量回答，不证明三个评估彼此统计独立；每维至少3/4、分布集中度至少0.5才快速接受；live 不确定时至多一次 LLM 深度复核。全部结果仍须实际行为 Gate。

批次	题目	Jev 状态	首候选 Gate	选中候选	选中 Gate	输入 Token	估算 USD
f0c7b845	MOCK-01	error	失败	未选择	未选择/unknown	3386	0.000142212
f0c7b845	MOCK-02	skipped	未执行	未选择	未执行	未请求	未请求
f0c7b845	MOCK-03	skipped	未执行	未选择	未执行	未请求	未请求
807e9dc4	MOCK-01	accepted	失败	candidate-b	通过	3386	0.000142212
807e9dc4	MOCK-02	uncertain	通过	系统弃权	未选择/unknown	3432	0.000144144
807e9dc4	MOCK-03	accepted	失败	candidate-b	通过	3442	0.000144564

全部 2 个启动批次保存在 jev-benchmarks.json，包括失败；error 是协议失败、skipped 没有执行，不是模型弃权。每题两份人工构造候选，不是真实生成；池、测试与阈值外呼前冻结，Jev 看不到缺陷标签或 Gate 结果。小样本不证明泛化、校准、最佳答案或稳定 L5。

批次 f0c7b845 / jev-candidate-v1：总体选中且通过 0/1，选择覆盖 0/1；已选中条件通过 unknown。配置不同不合并成功率。

批次 807e9dc4 / jev-candidate-v2：总体选中且通过 2/3，选择覆盖 2/3；已选中条件通过 2/2。配置不同不合并成功率。

混合/真实链路另存 mixed-and-live-runs.json：e436f153 终态 failed，未到最终Gate。全包 Jev 共 5 请求，输入 15027 / 输出 874 Token，估算 0.000631134 USD，包含旧失败、弃权和混合失败，不与 Mock 零生成费用混淆。完整 scope、unknown 与逐请求统计见 materials-summary.json。

固定 jev-1.13.0，单次不重试；每对照批次最多3请求、196608总Token、1 USD估算限额，非整个材料包总请求上限。按保存费率快照估算，不是供应商账单；缺usage为unknown。confidence 是分布集中程度，不是业务正确率。[官方 API](#) · [版本与价格](#) · [集中度](#)

托管 TypeSafe Jev 已接入，AnyJev 本地 SDK 尚未接入。临时凭据曾在会话提供，需用户轮换；材料与录屏不包含密钥。当前可信固定静态 Mock、历史录屏、本机不可信产物截图三者分开，不将 iframe 旧视频当作安全证明。